

2. Ensamblado de las muestras secuenciadas

2.a. Análisis de calidad y procesamiento de las secuencias crudas:

2. 1. Secuencias Sanger - Preprocesamiento de secuencias con PreGap4:

Para el procesamiento de las lecturas obtenidas mediante la secuenciación por el método de Sanger, se empleó el módulo PreGap4 perteneciente al paquete bioinformático Staden. Este software permite automatizar el preprocesamiento de los electroferogramas crudos (en formato .ab1) previo a la etapa de ensamblado, ejecutando tres operaciones críticas y secuenciales: la asignación de valores de calidad por base (base calling), el recorte por baja calidad (quality clipping) y la identificación y remoción de secuencias del vector de clonación (vector clipping).

En primer lugar se procedió a cargar los archivos brindados por la cátedra en la ventana Files to Process, tal como se muestra en la figura 1.




Figura 1.

A continuación se configuran los módulos que ejecutará Pregap4 en la pestaña Configure Modules, como se muestra en la figura correspondiente. En esta etapa, la única modificación realizada fue en el módulo Quality Clip, donde se ajustó el parámetro de average quality, manteniendo el resto de las configuraciones por defecto.




Figura 2.

El recorte por calidad se parametrizó utilizando un umbral de Phred ≥ 20 , lo que garantiza la exclusión de todas aquellas posiciones con una probabilidad de error en el llamado de la base superior al 1%. Esta selección se fundamenta en que las regiones terminales (tanto en el extremo 5' como, principalmente, en el 3') de las lecturas Sanger suelen exhibir una atenuación en la intensidad de la señal fluorescente y un solapamiento de picos. De no removerse, estas bases de baja confianza introducirían ruido e inconsistencias topológicas durante el ensamblado, comprometiendo la exactitud de la secuencia consenso final.

Asimismo, la eliminación de las secuencias del vector es un paso crucial para la fidelidad del análisis. Debido a que todas las lecturas de una misma biblioteca metagenómica o de amplicones comparten las secuencias flanqueantes del vector de clonado, la permanencia de estos fragmentos comunes forzaría al algoritmo de ensamblado a agrupar lecturas de forma artificial (basándose en la secuencia del vector y no en la homología real del inserto de interés). Esto daría lugar a la generación de contigs artefactuales que no reflejarían la verdadera arquitectura genómica de *Brucella suis*.

Tras la ejecución del pipeline de filtrado, el programa discriminó y clasificó las lecturas generando archivos de reporte específicos: un archivo con la extensión .passed, el cual consolida el listado y las rutas de todas las secuencias que superaron

exitosamente los umbrales de calidad y un archivo .failed, que registra aquellas lecturas rechazadas durante el proceso. En paralelo, para cada secuencia aprobada se generó su respectivo archivo de experimento en formato .exp (contentivo de la secuencia depurada y sus metadatos de calidad) junto con archivos de traza estandarizados .scf. Finalmente, este conjunto de datos quedó indexado en un archivo de lista global (.fofn, File of Filenames), estructurando de manera automatizada el lote de lecturas óptimas listo para ser importado en la base de datos del ensamblador.

A continuación se exponen las figuras del 3 al 5, donde se pueden observar algunos electroferogramas procesados con sus respectivos cortes, de vector, de calidad, y de ambos.




Figura 3. Corte de secuencia de vector al inicio de la secuencia




Figura 4. Corte por calidad al final de la secuencia




Figura 5. Corte por calidad y vector al inicio de la secuencia

Tras completar la rutina de preprocesamiento en PreGap4, se obtuvieron 242 secuencias con la calidad óptima para proceder al ensamblado, partiendo de un total de 242 electroferogramas crudos procesados. Aquellas lecturas que fueron completamente descartadas corresponden a secuencias que, luego de pasar por los filtros estrictos de calidad y remoción de vector, no alcanzaron la longitud mínima requerida para asegurar un solapamiento confiable durante el ensamblaje.

2. 2. *Secuencias Illumina - Análisis de calidad con fastqc*

Para el análisis de calidad de las lecturas cortas generadas por tecnología Illumina se utilizó el programa FastQC, herramienta estándar en el campo de la genómica para la evaluación de datos NGS. A diferencia de las secuencias Sanger, las lecturas Illumina no fueron sometidas a ningún procesamiento adicional, tal como indica la consigna, dado que SPAdes, programa que se utilizará en el ensamblado, incorpora internamente mecanismos de corrección de errores y tolerancia a lecturas de calidad variable.

La elección de FastQC se justifica en que permite caracterizar de forma rápida y visual los parámetros más relevantes de una corrida de secuenciación: distribución de calidad por posición, contenido de GC, presencia de adaptadores y secuencias sobrerrepresentadas, entre otros. Estos datos son indispensables para interpretar correctamente los resultados del ensamblado posterior.

Partimos del archivo "[Set3.fq](#)", donde al abrirlo podemos determinar que corresponde a una biblioteca SE ya que, en primera instancia, solo tenemos ese archivo en el caso de tener biblioteca PE deberíamos tener el archivos de las secuencias forward y su correspondiente reverse. Además, en los encabezados de las secuencias vemos el término R1 esto generalmente indica que esa secuencia proviene de la lectura directa o hacia adelante (forward read).

```

@T0_RID43_S0_CP010851.1_revcomp_258000_288000:16441-16590_length:150_mod0000 F0 R1
GTCGGTATTTTTCGGTGCGCCCCGATGAGGAGGCGGGATATCTCGCTGCAAGGCCGCCACGGCGGCACCATCTGGCGAAGGCAATATAGG
CGCGGGCGCAGGCGCCACCGTCGGCAAGATGTTTCGGCATGGATTACGCCATGAAGGGC
+
CCCGGGCGGGC8GGJCJGJJJJJJJJGJGJ=JGJGGCGJJJJJC
(JC=GJGJCJJGJJGCGJGJGJGJ8JJG1JJGGGG1JJGJJJ8JJCGJGJGGJJCG8GGGGGGGGGG8GGGG=GGG8GCGCC8CGCGGG
CGCG=CGGGCGC=
@T0_RID126_S0_CP010851.1_revcomp_258000_288000:6274-6423_length:150_mod0000 F0 R1
ATTAAGTTATGGTTCGGCGTGAGGGTATTTTCCTGCTGAACAGAAAGAACGACCGCATGGAGTTGCTCTCCATAAGGGAGTTTCGACGCAT
TCAGCGGGAAAAATACACCACGTCGCTCCGCGATATGACGAAAAATACCCATCTTGCGG
+
CC1GGGGGGGGGGJGGJJJJJJJJG1JJJJGJGJJJJJJGGGJJGGJJGJJGGJJGJGJGJ=G=JJJGGCCJGJGJJC=JJG
JGJCJJGCGJGGG=GGGGGGGGGGGGCGCGCGC==GCGGGG=8GGCGG=CC8C=CGG=
@T0_RID15_S0_CP010851.1_revcomp_258000_288000:18009-18158_length:150_mod0000 F0 R1
GCTGGCGCCATACCGCCACATGGGTGGGGCGGATACGCTCGTCACGCCAGTCACCTCCAACACCGCATTGGAAGCCGCTTTCCCAAGGT
TTTGAGAACGCGCTCGGTTTCGCTTATGTCATCGCAAGCATGGCACAGGCATCCACG
+
CC8=GGGGGGGGGJJJJJJJJGJJJJJJJJGJCCJGJGJJGJ=GJJJGJJJGJJGJJGJJ1==GGGGJCGJCCJG=CCGJJGJGJGCCC
JGJGJJCGGGGGC1GGGGCGC8GG=G=CGGGGGGGGGCGGGGGG(CGGCGC=C=GGC

```

Figura 6: Primeras líneas del archivo set3.fq

Es importante mencionar que el archivo .html generado por FastQC se encuentra disponible en el [siguiente enlace](#), donde puede consultarse el informe completo de calidad de las lecturas. A partir de este reporte, se detallan a continuación los distintos módulos de control de calidad, indicando aquellos que fueron aprobados, los que presentaron advertencias y los que no superaron los criterios establecidos por la herramienta, junto con una breve interpretación de cada caso.




Figura 7.

2.1. Basic Statistics

En esta sección podemos ver datos generales de nuestras secuencias. Como vemos en la figura, a continuación, tenemos un total de 65000 secuencias cada una de ellas con una longitud de 150pb

Measure	Value
Filename	Set3.fq
File type	Conventional base calls
Encoding	Sanger / Illumina 1.9
Total Sequences	65000
Total Bases	9.7 Mbp
Sequences flagged as poor quality	0
Sequence length	150
%GC	55

Figura 8. Salida de Basic statistics

2.2. Per base sequence quality

En esta sección podemos visualizar cómo se distribuyen los valores de calidad a lo largo de las secuencias, donde se construyen boxplots para cada nucleótido que representará la variación de los phred en la misma posición en las 65000 secuencias

Este gráfico está dividido en 3 zonas coloreadas de diferentes colores (verde, amarillo y rojo) donde se espera que las medianas de los boxplot caigan en la zona verde representando un valor phred mayor a 30.

En la figura podemos ver nuestra salida. Como es esperable se observa que la distribución de los valores de phred para cada posición se encuentra dentro de la región verde. Se presentan solo outliers de baja calidad en las posiciones 3 y 150. Este comportamiento en la última posición es esperable ya que puede suceder que las enzimas necesarias para la secuenciación comienzan a desgastarse.

A pesar de estos valores, encontramos que la calidad promedio (línea azul) es aceptable ya que se encuentra en la región de valor phred mayor a 30




Figura 9. Salida de Per base sequence quality

2.3. Per sequence quality scores

Este tipo de test nos realiza un gráfico donde en el eje X vemos el score de calidad Phred promedio de cada lectura completa, y en el eje Y es el número de lecturas con ese score promedio.

Como podemos observar todas las secuencias caen en una calidad promedio entre 35 y 38, estando la mayor cantidad de ellas entre estos valores (36-37). Dado que consideramos como umbral de buena calidad un phred mayor a 30 podemos decir que todas caen en valores mayores a este de forma que las mismas presentan una calidad promedio aceptable




Figura 10. Salida de Per sequence quality score

2.4. *Per base sequence content*

En esta sección podemos ver la distribución de las bases en la secuencia donde podemos esperar que si se hizo una biblioteca aleatoria hubiera poca o ninguna diferencia entre las distintas bases de una secuencia, por lo que las líneas de este gráfico deberían ser paralelas. Al tener una biblioteca aleatoria obtenemos una mayor representatividad de la secuencia que fue secuenciada de forma que todas las regiones tienen chances similares de ser secuenciadas, este tipo de bibliotecas produce coberturas más homogéneas, siendo esto muy importante para el ensamblado de genomas.

Esto es lo que observamos en la Figura , líneas paralelos sin sesgos.




Figura 11. Salida Per base sequence content

2.5. Per sequence GC content

Esta sección permite analizar la distribución del contenido de G+C (guanina y citosina) en cada lectura, comparándola con una distribución teórica esperada para una biblioteca aleatoria. Su objetivo es detectar posibles sesgos en la composición de las secuencias, los cuales pueden deberse tanto a características biológicas del organismo como a artefactos técnicos del proceso de secuenciación o preparación de la biblioteca.

En una biblioteca ideal, se espera una distribución aproximadamente normal, unimodal y simétrica, centrada en el porcentaje de GC característico del organismo en estudio. La curva observada debería ajustarse razonablemente a la distribución teórica generada por FastQC.

En este caso, la distribución observada muestra un corrimiento hacia valores elevados de GC, junto con una forma más estrecha y asimétrica en comparación con la distribución teórica. Por este motivo, el módulo aparece marcado como “fail”. Además, se aprecia una ligera cola hacia valores bajos de GC, lo que indica que la composición no es completamente homogénea entre las lecturas.

No obstante, este resultado no implica necesariamente una mala calidad global de la secuenciación. En organismos con genomas naturalmente ricos en GC, o en regiones genómicas con este sesgo composicional, es esperable observar desviaciones

respecto de la distribución teórica. Asimismo, durante la amplificación por PCR o la preparación de la biblioteca pueden introducirse sesgos que favorezcan ciertas secuencias. Por lo tanto, mientras otros indicadores de calidad (como los scores Phred, la presencia de adaptadores o la calidad por base) sean adecuados, esta desviación puede interpretarse más como una característica de la muestra que como un problema crítico del proceso de secuenciación.




Figura 12.

2.6. Per base N content

Esta sección nos permite observar el contenido de N en la secuencia o sea contenido de nucleótidos que el base calling no pudo asignar correctamente y le puso un valor de N.

Esperamos un bajo contenido de N, esto es lo que observamos en la Figura , indicándonos una buena calidad




Figura 13.

2.7. Sequence Length Distribution

Esta sección nos permite observar la distribución de la longitud de la secuencia como bien podemos ver se centran en 150 porque se usó Illumina y esta tiene todas las secuencias en los mismos tamaños.




Figura 14.

2.8. Sequence Duplication Levels

Esta sección permite evaluar cuántas veces se repite cada secuencia dentro del conjunto de lecturas, con el objetivo de identificar el nivel de redundancia de la biblioteca. Este análisis es útil para detectar posibles eventos de sobreamplificación

por PCR, baja complejidad de la muestra o enriquecimiento de ciertas regiones o secuencias específicas.

En una biblioteca idealmente aleatoria y de alta complejidad, se espera que la mayoría de las lecturas sean únicas, con una disminución progresiva en la frecuencia a medida que aumenta el nivel de duplicación. Es decir, el comportamiento esperado es que predominen ampliamente las secuencias no duplicadas.

En este caso, se observa que una proporción considerable de las lecturas presenta entre 2 y 4 repeticiones, mientras que los niveles de duplicación más altos son poco frecuentes. FastQC marca este resultado como “warning”, dado que el porcentaje de secuencias únicas tras la deduplicación es cercano al 64%, lo que indica una redundancia moderada en la biblioteca.

Sin embargo, este resultado no implica necesariamente una baja calidad de la corrida. En bibliotecas con alta profundidad de secuenciación, genomas pequeños, regiones altamente expresadas o fragmentos naturalmente enriquecidos, es esperable observar cierto grado de duplicación. Además, un sesgo severo por PCR generalmente se manifiesta con picos pronunciados en niveles de duplicación elevados, lo cual no se evidencia en este caso. Por lo tanto, los resultados sugieren una redundancia moderada, sin indicios claros de un problema crítico en la calidad global de los datos.




Figura 15.

2.9. Overrepresented sequences

Esta sección muestra si hay secuencias que aparecen muchas más veces de lo esperado dentro del conjunto de lecturas. Sirve para detectar posibles contaminaciones, restos de adaptadores, secuencias ribosomales, errores de PCR o también regiones del genoma que estén naturalmente muy representadas.

En una biblioteca ideal no deberían aparecer secuencias claramente sobre-representadas, salvo en casos donde por la biología de la muestra haya moléculas muy abundantes. En este análisis se encontraron algunas secuencias enriquecidas, pero en proporciones muy bajas (menos del 0,3%). Además, FastQC no pudo asociarlas con adaptadores conocidos, por lo que aparecen como “No Hit”.

La advertencia que genera FastQC se debe a que estas secuencias superan el umbral estadístico esperado, pero al ser tan poco frecuentes no afectan de forma importante la calidad general de la biblioteca. Lo más probable es que se trate de regiones naturalmente abundantes o de algún sesgo leve de amplificación, más que de una contaminación o error técnico relevante.

Sequence	Count	Percentage	Possible Source
TGACGACCGACAAGGTTCTGGCCGATCTCAAGGGTATCGGCGGCACGGTT	158	0.24307692307692308	No Hit
AAGTACCCGTGGGTGCCGTTTGCGTGGCGCTGGACACAACATGTTTCGGCA	145	0.22307692307692306	No Hit

Figura 16.

2.10. Adapter content

Esta sección me indica el porcentaje de adaptadores donde esperamos que no haya o que su presencia sea mínima porque durante el procesamiento idealmente los adaptadores se removieron y las secuencias corresponden únicamente a las secuencias de interés.

Esto es lo que observamos




Figura 17.

2.b. Ensamblado de secuencias largas con Gap4

El ensamblado de novo de las lecturas de secuenciación por Sanger previamente depuradas y normalizadas por PreGap4 se llevó a cabo mediante el programa Gap4, el componente central de edición y ensamblado del paquete Staden. Gap4 implementa un algoritmo heurístico fundamentado en el paradigma de Solapamiento-Distribución-Consenso (OLC, Overlap-Layout-Consensus). Este enfoque está específicamente diseñado para lecturas largas (típicamente de 500 a 900 pb) con perfiles de error distribuidos principalmente en los extremos, permitiendo la identificación de regiones de superposición (overlaps) significativas y la alineación progresiva de las lecturas para la reconstrucción jerárquica de bloques contiguos de secuencia o contigs.

A diferencia de los ensambladores modernos optimizados para secuenciación de segunda generación (NGS), los cuales se basan en grafos de De Bruijn y colapsan la información de calidad, Gap4 preserva y procesa de forma nativa los valores de calidad Phred (Q) individuales de cada nucleótido durante toda la arquitectura del ensamblaje. Al momento de resolver ambigüedades o discordancias en columnas de alineamiento múltiple, el software ejecuta un cálculo matricial ponderado. En posiciones donde coexisten bases diferentes entre lecturas solapadas, el algoritmo asigna un peso estadístico estrictamente proporcional al valor Q de cada base individual. De este modo, una base con calidad excelente predomina inequívocamente sobre llamados de baja confianza mitigando la

incorporación de artefactos de secuenciación o errores de polimerasa en la secuencia consenso final y garantizando una alta fidelidad en regiones con cobertura redundante.

Para la ejecución del proceso, se parametrizó la modalidad de ensamblado "Normal shotgun assembly", una estrategia idónea para proyectos genómicos basados en bibliotecas de fragmentación aleatoria (como la empleada para el análisis de *Brucella suis*). Acá cargamos el archivo pregap.passed obtenido en el punto anterior y seleccionamos un archivo de salida .txt para ver si hay errores a la hora de ejecución.




Figura 18.




Figura 19. ESTA BIEN :)

Una vez concluida la rutina iterativa de ensamblado y resueltos los solapamientos legítimos, se obtuvo un total de 9 contigs.




Figura 20.

The screenshot shows a window titled "Contig List". It contains a table with three columns: "Name", "Length", and "# sequences". The table lists nine contigs. At the bottom of the window, there is a toolbar with buttons for "Cancel", "Save order", "Copy", and "Help".

Name	Length	# sequences
GBUBM92TR (#187)	14532	126
GBRBC20TF (#22)	4334	43
GBRAN41TR (#11)	693	1
GBUBA83TR (#167)	8257	67
GBREH88TF (#104)	474	1
GBUAW83TF (#161)	86	1
GBUAZ20TF (#164)	580	1
GBUBE21TF (#173)	437	1
GBUCN09TF (#223)	850	1

Figura 21.

Ahora uniremos los contigs (COMPLETAR DESCRIPCION)




Figura 22.




Figura 23. (se dejan parametros por defecto, justificar porque=




Figura 24.

al hacer las uniones recomendadas y seguidamente supervisadas en cuanto al porcentaje de mismatch pongo cap de mismatch y ver que poner o establecer una justificacion

0–1% mismatch: unión normalmente muy confiable ✓

1–3% mismatch: revisar manualmente el alineamiento y los cromatogramas ⚠

>3–5% **mismatch**: sospechar que no son la misma región, errores, repetidos o ensamblado incorrecto ❌




Figura 25.




Figura 26. (no uni)

poner con cuantos contigs nos quedamos con ese criterio

Matias Rios tiene los archivos unidos consenso.

2.c. Ensamblado híbrido

Luego de obtener el consenso final a partir de las secuencias generadas por Sanger y procesadas mediante el programa GAP4, se realizó un ensamblaje híbrido utilizando el ensamblador SPAdes (St. Petersburg genome assembler). Este tipo de ensamblaje permite combinar información proveniente de tecnologías de secuenciación con características

diferentes: por un lado, las lecturas largas y de alta continuidad obtenidas mediante Sanger, y por otro, las lecturas cortas pero de alta profundidad generadas mediante Illumina.

En este caso, el consenso final obtenido en GAP4 (*consensofinal.fasta*) fue utilizado como *trusted contig*, es decir, como una secuencia previamente ensamblada y de alta confianza que SPAdes utiliza como referencia durante la construcción del ensamblaje final. La incorporación de esta información permite reducir la fragmentación del ensamblaje y mejorar la resolución de regiones difíciles de reconstruir únicamente con lecturas cortas.

Las lecturas Illumina correspondientes a la biblioteca utilizada (*Set3.fq*) fueron ingresadas como datos principales del ensamblaje. Debido a que estas lecturas corresponden a una biblioteca de lecturas simples (*single-end reads*), se utilizó el parámetro correspondiente de SPAdes para este tipo de entrada.

El ensamblaje híbrido fue ejecutado utilizando el siguiente comando:

```
$ spades.py -s Set3.fq --trusted-contigs consensofinal.fasta -o spades_hybrid
```

Los parámetros utilizados fueron:

- *-s Set3.fq*: especifica el archivo de lecturas Illumina de tipo *single-end* utilizado para el ensamblaje.
- *--trusted-contigs consensocontig2gap4.fasta*: incorpora el consenso obtenido mediante Sanger como *contig* confiable para guiar la reconstrucción.
- *-o spades_hybrid*: indica el directorio donde se almacenan los archivos generados por SPAdes.

No se incorporaron parámetros adicionales, siguiendo las indicaciones del protocolo experimental, con el objetivo de evaluar el desempeño del ensamblador utilizando únicamente la información proporcionada por las lecturas Illumina y el ensamblaje previo obtenido por Sanger.

El archivo generado por SPAdes utilizado para el análisis posterior fue *spades_hybrid/contigs.fasta*

La evaluación de la calidad del ensamblaje obtenido se realizó mediante QAST (Quality Assessment Tool for Genome Assemblies). Esta herramienta permite analizar parámetros como número de contigs, longitud total ensamblada, continuidad del ensamblaje, valores de N50 y L50, contenido GC y presencia de bases ambiguas.

El análisis se realizó mediante:

```
$ quast.py spades_hybrid/contigs.fasta -o quast_hybrid
```




Figura 27.

El análisis reveló la presencia de un único contig en el ensamblaje final (# contigs = 1), con una longitud total de 30.000 pares de bases. Además, este único contig supera todos los filtros de longitud evaluados por QUAST (≥ 1000 pb, ≥ 5000 pb, ≥ 10000 pb y ≥ 25000 pb), indicando que la totalidad de la secuencia ensamblada corresponde a un único fragmento largo y continuo. La ausencia de contigs adicionales pequeños sugiere que el ensamblador logró integrar correctamente la información proveniente de las lecturas Illumina y del contig confiable generado a partir de Sanger.

El valor de N50 obtenido fue de 30.000 pb, coincidiendo con la longitud total del ensamblaje. El parámetro N50 indica la longitud para la cual el 50% del ensamblaje está contenido en contigs de igual o mayor tamaño. En este caso, al existir solamente un contig, toda la longitud ensamblada está representada por ese único fragmento, evidenciando una máxima continuidad del ensamblaje. De manera consistente, el valor de L50 fue igual a 1, lo que significa que solamente un contig es necesario para representar al menos la mitad del ensamblaje total.

De forma complementaria, el valor de N90 también fue de 30.000 pb y el valor de L90 fue 1, indicando que incluso para representar el 90% de la secuencia ensamblada solo es necesario considerar el único contig generado. Estos resultados confirman que el ensamblaje no presenta regiones fragmentadas ni múltiples secuencias parciales.

El contenido de GC fue de 55,57%, valor calculado sobre la totalidad de la secuencia ensamblada. Este porcentaje representa la proporción de bases guanina y citosina presentes en el genoma reconstruido y permite caracterizar la composición nucleotídica del ensamblaje. Al no observarse valores anómalos de GC dentro del contig, no se evidencian regiones con composiciones extremadamente diferentes que puedan sugerir contaminación o ensamblajes incorrectos.

Otro resultado relevante es la ausencia de bases ambiguas: QUAST reportó 0 Ns en el ensamblaje y una cantidad de 0 bases ambiguas por cada 100 kpb. Esto indica que la secuencia consenso final no contiene posiciones sin resolver y que cada región fue determinada con una base específica, aumentando la confiabilidad del ensamblaje obtenido.

La combinación de los datos Sanger y las lecturas Illumina permitió aprovechar las ventajas de ambas tecnologías. El consenso obtenido previamente en GAP4 aportó información estructural de mayor longitud que facilitó la reconstrucción del genoma, mientras que las lecturas Illumina proporcionaron una alta profundidad de secuenciación para mejorar la precisión del consenso final. Como resultado, SPAdes logró generar un ensamblaje compuesto por un único contig de 30 kb, con alta continuidad, sin regiones ambiguas y con una estructura completamente resuelta.

Podemos concluir que los parámetros obtenidos por QUAST indican que el ensamblaje híbrido presenta una calidad excelente, caracterizada por un único contig, valores máximos de continuidad (N50 y N90 equivalentes a la longitud total), ausencia de gaps y ausencia de bases ambiguas. Esto demuestra que la estrategia híbrida fue efectiva y permitió obtener una reconstrucción completa y confiable de la secuencia analizada.